

2. Maticová algebra

Maticový součin $A \in \mathbb{R}^{m \times p}$ a $B \in \mathbb{R}^{p \times n}$ je $C \in \mathbb{R}^{m \times n}$
 $c_{ij} = \sum_{k=1}^p a_{ik} b_{kj}$ $i=1, \dots, m$ $j=1, \dots, n$

Čtvercová matice je

- symetrická $\Leftrightarrow A^T = A$
- antisym. $\Leftrightarrow A^T = -A$ (a toho plyne $a_{ii}=0$)

Inverze $m \times m$ $m \times n$ if ex. p. i. l. inv. \Rightarrow normální se a jsou jediné
 $AB = I_m$ (an. A^{-1})

levá inv. B A^T reg. A AA^T reg. A AA^T reg. A
 ex. iff B má LN sloupce ex. iff A má LN řádky

Determinant (mat. $A \in \mathbb{R}^{n \times n}$) $\det A = \sum_{\sigma \in S_n} \text{sgn } \sigma \prod_{i=1}^n a_{i, \sigma(i)}$
 $\det A^{-1} = (\det A)^{-1}$ $\det A^T = \det A$

Ystopa (chr. mat. $A \in \mathbb{R}^{n \times n}$) $\text{tr } A = a_{11} + \dots + a_{nn}$
 $\langle A, B \rangle = \text{tr}(A^T B)$, $\|A\| = \sqrt{\langle A, A \rangle}$
 $\text{rng } A = \{A\vec{x} \mid \vec{x} \in \mathbb{R}^n\}$
 mn. v. hodnota matr. $f(\vec{x}) = A\vec{x}$
 mn. v. g. pro k. n. $A\vec{x} = \vec{y}$ res.
 lin. d. sloupce A

$(\text{rng } A)^{\perp} = \text{null}(A^T)$, $(\text{null } A)^{\perp} = \text{rng}(A^T)$
 $\text{rng}(AB) \subseteq \text{rng } A$; normost, pokud řádky B jsou LN
 $\text{null}(AB) \supseteq \text{null } B$; normost, pokud sloupce A jsou LN
 $\text{rng}(A^T A) = \text{rng}(A^T)$, $\text{null}(A^T A) = \text{null } A$
 $\text{rank } A = \dim \text{rng } A$ $\text{rank } A = \text{rank}(A^T)$
 $\text{rank } A \leq \min\{m, n\}$; normost \Leftrightarrow mat. A má plnou hodnotu
 $\text{rank}(AB) \leq \min\{\text{rank } A, \text{rank } B\}$
 $\dim \text{rng } A + \dim \text{null } A = n$ ($A \in \mathbb{R}^{m \times n}$)

Afinní podprostor a sobezeseni
 cf. komb.: $a_1 \vec{x}_1 + \dots + a_k \vec{x}_k$, kde $a_1 + \dots + a_k = 1$
 mn. A je af. podpr. iff je mn. řes. nej. soustav $A\vec{x} = \vec{b}$
 cf. nezav.: $a_1 + \dots + a_k = 0$, $a_1 \vec{x}_1 + \dots + a_k \vec{x}_k = \vec{0} \Rightarrow a_1 = \dots = a_k = 0$

4. Ortogonálnost $\cos \varphi = \frac{\langle \vec{x}, \vec{y} \rangle}{\|\vec{x}\| \|\vec{y}\|}$ $\vec{x} \perp \vec{y} \Leftrightarrow \langle \vec{x}, \vec{y} \rangle = 0$
 $\vec{y} \perp \text{span}\{\vec{x}_1, \dots, \vec{x}_k\} \Leftrightarrow \vec{y} \perp \vec{x}_1, \dots, \vec{y} \perp \vec{x}_k$

Matice s ortonormalními sloupci ($A \in \mathbb{R}^{m \times n}$)
 (nutně $m \geq n$), $A^T A = I$

isometrie (zachovává skel. součin, vzdálenosti, úhly)
 Bro. každou chr. $U: \mathbb{R}^n \rightarrow \mathbb{R}^m$ $U^T U = I \Leftrightarrow U U^T = I$
 $\det U \in \{1, -1\}$ $\det U = 1$, $\det U = -1$
 nebez. složením otočení a ortog. reflexe

Gram-Schmidtova ortonormalizace
 $q_1 = a_1$, $q_1 = q_1 / \|q_1\|$
 $q_2 = a_2 - (q_1^T a_2) q_1$, $q_2 = q_2 / \|q_2\|$
 $q_3 = a_3 - (q_1^T a_3) q_1 - (q_2^T a_3) q_2$, $q_3 = q_3 / \|q_3\|$
 $A = QR$, Q ortog., R [] ; řešení $A\vec{x} = \vec{b}$: $R\vec{x} = Q^T \vec{b}$
 (chr. úprava pro plný QR rozklad)

5. Nehomogenní lineární soustavy ($A\vec{x} = \vec{b}$)
 nemá řes. $\Leftrightarrow \vec{b} \notin \text{rng } A$ převedení $m \times n$ n m
 jediné řes. $\Leftrightarrow \vec{b} \in \text{rng } A$ & A má LN sloupce
 nek. mn. řes. $\Leftrightarrow \vec{b} \in \text{rng } A$ & A má LZ sloupce ... nedostatek

Přibližné řešení ve smyslu nejmenších čtverců
 $\min_{\vec{x} \in \mathbb{R}^n} \|A\vec{x} - \vec{b}\|^2 = \min_{\vec{y} \in \text{rng } A} \|\vec{y} - \vec{b}\|^2$, $\vec{y} \in \text{rng } A$
 $A^T A \vec{x} = A^T \vec{b} \rightarrow \vec{x} = (A^T A)^{-1} A^T \vec{b}$ reg. $\Leftrightarrow A$ má LN sloupce
 má vždy řes. A^+ ... levá pseudoinverze k A

Ortogonalní projekce na podprostor
 ortog. projekce P na X : vektor $\vec{y} \in X$ splň. $(\vec{y} - \vec{y}) \perp X$
 ortog. projektor: $P = AA^+ = A(A^T A)^{-1} A^T$ na $X = \text{rng } A$
 ortog. projekce podm.: $P^2 = P$, & $P^T = P$
 P projektor na $X \Leftrightarrow P(I - P)$ ort. projektor na X^{\perp}

6. Spektrální rozklad a kvadr. funkce

$A\vec{v} = \lambda \vec{v}$, $\vec{v} \neq \vec{0} \rightarrow (A - \lambda I)\vec{v} = \vec{0}$, $\lambda \neq 0$
 $(m \times n)$ $(n \times n)$ $(n \times n)$ $(n \times n)$ $(n \times n)$ $(n \times n)$
 $\det(A - \lambda I) = 0$
 $\lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ $V = [\vec{v}_1 \dots \vec{v}_n]$ $\vec{0}$
 $AV = V\lambda$ A je diagonalizovatelná $\Leftrightarrow V$ reg.
 $A = V\lambda V^{-1} = \sum_{i=1}^n \lambda_i \vec{v}_i \vec{v}_i^T + \dots + \lambda_n \vec{v}_n \vec{v}_n^T$
 A je spektrální rozklad
 A sym. \Rightarrow vs. vl. č. jsou reálná a ex. ort. mn. n vektorů
 lze rozložit spektr. rozkladem

Kvadratická forma (homog. polynom $f: \mathbb{R}^n \rightarrow \mathbb{R}$ druhého st.)
 $f(\vec{x}) = \vec{x}^T A \vec{x} = \vec{x}^T (\frac{1}{2}(A + A^T)) \vec{x}$
 A pozit. semidef. $\Leftrightarrow \vec{x}^T A \vec{x} \geq 0$ pro vs. $\vec{x} \in \mathbb{R}^n$
 - vl. č. A jsou ≥ 0
 - ex. $B \in \mathbb{R}^{n \times n}$ tak, že $A = B^T B$ pro sym. A
 - vs. hl. minory jsou ≥ 0
 A pozit. def. $\Leftrightarrow \vec{x}^T A \vec{x} > 0$ pro vs. $\vec{x} \in \mathbb{R}^n \setminus \{\vec{0}\}$
 - vl. č. A jsou > 0
 - ex. reg. $B \in \mathbb{R}^{n \times n}$ tak, že $A = B^T B$ pro sym. A
 - vs. v. hl. minory jsou > 0

A indef. \Leftrightarrow ex. \vec{x} a \vec{y} tak, že $\vec{x}^T A \vec{x} > 0$ a $\vec{y}^T A \vec{y} < 0$
 A neg. [semi] def. $\Leftrightarrow -A$ poz. [semi] def.
 A indef. - má alespoň jedno vl. č. > 0 a jedno < 0
 A neg. [semi] def. - není poz. ani neg. def.

Diagonalizace kvadr. formy (A sym.)
 $f(\vec{x}) = \vec{x}^T A \vec{x} = (\vec{x}^T V) \lambda (V^T \vec{x}) = \vec{y}^T \lambda \vec{y}$

7 PCA pro $A = [\vec{a}_1 \dots \vec{a}_n]$: $\min_{\substack{\vec{y} \in \mathbb{R}^m \\ \vec{y} \perp \vec{a}_1, \dots, \vec{a}_{k-1}}} \sum_{i=1}^k \|\vec{y} - \vec{a}_i\|^2$ za podm. $(\text{rng } X = (\text{rng } Y)^{\perp})$
 $\vec{y} \in \mathbb{R}^{m \times (m-k)}$, $X^T X = I$

hledáme rng Y dim. $k \leq m$ minimalizující součet
 $\sum_{i=1}^k \|\vec{y} - \vec{a}_i\|^2 = \sum_{i=1}^k \vec{y}^T A A^T \vec{y} = \text{tr}(X^T A A^T X)$
 $\vec{y}_1, \dots, \vec{y}_k$ sloupce X

Úloha na nejmenší stopu $\text{rng } Y$
 $B \in \mathbb{R}^{m \times m}$ sym., $B = V\lambda V^T$, vl. č. $\lambda_1 \leq \dots \leq \lambda_m$, $k \leq m$:
 $\min \{ \text{tr}(X^T B X) \mid X \in \mathbb{R}^{m \times k}, X^T X = I \} = \lambda_1 + \dots + \lambda_k$
 a minimum se nabývá pro $X = [\vec{v}_1 \dots \vec{v}_k]$.

PCA - řešení

- Pro $AA^T \in \mathbb{R}^{m \times m}$ spočítáme $V\lambda V^T$ a seř. vl. č.
 vzeskupíme: $\lambda_1 \leq \dots \leq \lambda_m$
- Čtenáříme $V = [\vec{v}_1 \dots \vec{v}_{m-k} \mid \vec{v}_{m-k+1} \dots \vec{v}_m]$
- Sloupce $Y \in \mathbb{R}^{m \times k}$ jsou orton. bázi hledaného podpr. dim. k
- Optimální hodnota úlohy $\lambda_1 + \dots + \lambda_{m-k}$ je chyba přeložení

Nejbližší matice nižší hodnoty (low rank approximation)
 pro $A = [\vec{a}_1 \dots \vec{a}_n]$: $\min \{ \|A - B\|^2 \mid B \in \mathbb{R}^{m \times n}, \text{rank } B \leq k \}$
 \rightarrow optimální řes. je $B = YY^T A = (I - XX^T) A$
 probl. cf. podm.: od \vec{a}_i odečteme $\vec{a}_i = \sum_{j=1}^k (\vec{a}_i^T \vec{v}_j) \vec{v}_j$ a řes. je $Y + \vec{z}$

SVD: lib. $A \in \mathbb{R}^{m \times n} \rightarrow A = USV^T = \sum_{i=1}^r \sigma_i \vec{u}_i \vec{v}_i^T + \dots + \sigma_p \vec{u}_p \vec{v}_p^T$
 $\sigma_1 \geq \dots \geq \sigma_p \geq 0$ $m \times p$ $p \times p$ $m \times p$ $p = \min\{m, n\}$
 $AA^T = US^2 U^T$ AA^T a AA^T mají stejné nenulové vl. č. $\lambda_i = \sigma_i^2$
 $A^T A = VS^2 V^T$ $U, V \dots$ orton. sloupce
 $S \dots$ diagonální (ne nutně čtvercová)
 low rank approx.: pro $k \leq p$ je řes. $B^* = US_k V_k^T$, $S_k = \text{diag}(\sigma_1, \dots, \sigma_k, 0, \dots, 0)$
 $PCA: U_k = [\vec{u}_1 \dots \vec{u}_k] \in \mathbb{R}^{m \times k}$, opt. h. je $\sigma_{k+1}^2 + \dots + \sigma_p^2$
 $X = \{ \vec{x} \mid A\vec{x} = \vec{b} \} \xrightarrow{Y} Y^T \vec{b}$
 vzd. z od $X = \sqrt{(A^T A - k)(A^T A)^{-1}(A^T A - k)}$
 \rightarrow pro $X = \{ \vec{x} \mid A\vec{x} = \vec{b} \}$: $\frac{\|A^T A - k\|}{\|A\|}$

- levé sing. vektory \vec{u}_i jsou vl. vektory AA^T , pravé sing. vektory \vec{v}_i jsou vl. v. $A^T A$
- diag. prvky $S^2 = \begin{bmatrix} \sigma_1^2 & 0 & \dots \\ 0 & \sigma_k^2 & \dots \\ \vdots & \vdots & \ddots \end{bmatrix}$ jsou druhé mocniny diag. prvky S , tedy nenul. sing. č. A jsou druhé mocniny vl. č. AA^T a AAT
- $\vec{u}_i = \frac{A^T \vec{v}_i}{\sigma_i}$, $i=1, \dots, p$ ($U = AVS^{-1}$ pro rank-min SVD \rightarrow $\sigma_i = 0$ $i > p$)

Kvadratická funkce $f(\vec{x}) = \vec{x}^T A \vec{x} + \vec{b}^T \vec{x} + c$
 sym. \downarrow doplnění na čtverec
 $= (\vec{x} - \vec{x}_0)^T A (\vec{x} - \vec{x}_0) + y_0$
 $\vec{b} = -2A\vec{x}_0 \rightarrow$ reg. \vec{x}_0
 $c = \vec{x}_0^T A \vec{x}_0 + y_0$ des.
 (pokud $\vec{b} = -2A\vec{x}_0$ nemá řes., pak nelze doplnit na čtverec)

8. Derivace
 • f je diferencovatelná v bodě \vec{x} ex. v. por. der. $\frac{\partial f_i(\vec{x})}{\partial x_j}$ a jsou spoj.
 • $f'(\vec{x}) = \begin{bmatrix} \frac{\partial f_1(\vec{x})}{\partial x_1} & \dots & \frac{\partial f_1(\vec{x})}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m(\vec{x})}{\partial x_1} & \dots & \frac{\partial f_m(\vec{x})}{\partial x_n} \end{bmatrix}$, $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$
 ... Jacobioho matice

• $f: \mathbb{R}^n \rightarrow \mathbb{R}^m \rightsquigarrow f': \mathbb{R}^n \rightarrow \mathbb{R}^m$
 • gradient fee $f: \mathbb{R}^n \rightarrow \mathbb{R}$... $\nabla f(\vec{x}) = f'(\vec{x})^T$... sloupce vektor
 • směr der. $f(\vec{x}) = \lim_{\alpha \rightarrow 0^+} \frac{f(\vec{x} + \alpha \vec{n}) - f(\vec{x})}{\alpha}$ sestupný směr \vec{n} :
 \rightarrow pokud je f dif. v \vec{x} : $f(\vec{x}) = f'(\vec{x}) \vec{n}$
 \rightarrow nejvíce v směru $\vec{n} = \frac{1}{\|\nabla f(\vec{x})\|} \cdot \nabla f(\vec{x})$ pro $f: \mathbb{R}^n \rightarrow \mathbb{R}$
 \rightarrow nulová pro $\vec{n} \perp \nabla f(\vec{x})$
 • der. slož. robt. $h = g \circ f$: $h'(\vec{x}) = g'(f(\vec{x})) \cdot f'(\vec{x})$
 $f'(\vec{x}) = \begin{bmatrix} \frac{\partial^2 f(\vec{x})}{\partial x_1 \partial x_1} & \dots & \frac{\partial^2 f(\vec{x})}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\vec{x})}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f(\vec{x})}{\partial x_n \partial x_n} \end{bmatrix}$ Hessova matice
 • Taylorův polynom $T_{\vec{x}}^1(f) = f(\vec{x}) + f'(\vec{x})(\vec{y} - \vec{x}) + \frac{1}{2}(\vec{y} - \vec{x})^T f''(\vec{x})(\vec{y} - \vec{x})$
 if A sym.

$f(\vec{x})$	$f'(\vec{x})$	$f''(\vec{x})$	$f'(\vec{x})$	$f''(\vec{x})$
\vec{x}	$\vec{1}$	$\vec{x}^T A \vec{x}$	$\vec{x}^T A + A^T \vec{x} = 2 \vec{x}^T A$	$f''(\vec{x}) = A + A^T = 2A$
$A\vec{x} + \vec{b}$	A	$\ g(\vec{x})\ $	$\vec{x}^T A + A^T \vec{x} = 2 \vec{x}^T A$	$f''(\vec{x}) = A + A^T = 2A$
$g(A\vec{x} + \vec{b})$	$g'(A\vec{x} + \vec{b}) A$	$g(\vec{x})^T h(\vec{x})$	$g'(\vec{x})^T h(\vec{x}) + h'(\vec{x})^T g(\vec{x})$	$g, h: \mathbb{R}^n \rightarrow \mathbb{R}^m$

10. Volné lokální extrémy
 • podm. 1. řádu: $X \subseteq \mathbb{R}^n$, \vec{x} je m. bod X a $f: \mathbb{R}^n \rightarrow \mathbb{R}$ je dif. v \vec{x}
 \vec{x} je lok. extrém f na $X \Rightarrow f'(\vec{x}) = 0$ (\vec{x} je SB f)
 • podm. 2. řádu: $f''(\vec{x})$ je 2krát dif. v \vec{x}
 \vec{x} je SB f $\begin{cases} f''(\vec{x}) \text{ poz. semidef.} \Rightarrow \vec{x} \text{ lok. min.} \\ f''(\vec{x}) \text{ poz. def.} \Rightarrow \vec{x} \text{ ostré lok. min.} \\ f''(\vec{x}) \text{ ind.} \Rightarrow \vec{x} \text{ není lok. extrém} \end{cases}$

Metoda co počítá iterativní vzorec
 Gradientní $\min f$ $x = a - \nabla f(a)$ směr $\vec{v} = -\nabla f(a)$ je vždy sestupný
 Newtonova $g(\vec{x}) = \vec{0}$ $x = a - (g'(a))^{-1} g(a)$ selže, když je $f''(a)$ singularní
 Newtonova $\min f$ $x = a - (f''(a))^{-1} (f'(a))^T$ \vec{n} sest., když $f'(a)$ je poz. def. a $f'(a) \neq 0$
 Gauss-Newton $\min \|g(\vec{x})\|^2$ $x = a - (g'(a)^T g'(a))^{-1} g'(a)^T g(a)$ \vec{n} je vždy sest.
 Levenberg-Marquadt $\min \|g(\vec{x})\|^2$ $x = a - (g'(a)^T g'(a) + \mu I)^{-1} g'(a)^T g(a)$
 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$
 $f(x_k) < f(x_{k+1})$ is. přimene, μ zmenšíme (2. krok)
 $f(x_k) > f(x_{k+1})$ is. odmítáme, μ zvětšíme (2. krok)

11. Lokální extrémy v rovině normostnosti
 • $\vec{x} \in \mathbb{R}^n$ je regulární bod $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$, pokud řádky $g'(\vec{x})$ jsou LN
 • hledáme lok. extrémy fee $f: \mathbb{R}^n \rightarrow \mathbb{R}$ na mn. $X = \{\vec{x} \in \mathbb{R}^n \mid g(\vec{x}) = \vec{0}\}$
 • v reg. bodě \vec{x} robt. g je lineární prostor $L = \text{null } g'(\vec{x})$, ortog. prostor $(\text{null } g'(\vec{x}))^\perp$
 Lokální extrém f na X splňuje
 $\frac{\partial^2 L}{\partial \vec{x}^2} = f'(\vec{x}) + \vec{\lambda}^T g'(\vec{x}) = \vec{0}$ pro $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$
 $\frac{\partial^2 L}{\partial \vec{x}^2} = g'(\vec{x}) = \vec{0}$
 • Lagrangeova funkce $L(\vec{x}, \vec{\lambda}) = f(\vec{x}) + \vec{\lambda}^T g(\vec{x})$
 • nulová podm. pro vztahy extrém: $\nabla f(\vec{x}) \in T^\perp$
 $L'(\vec{x}, \vec{\lambda}) = [f'(\vec{x}) + \vec{\lambda}^T g'(\vec{x}), g'(\vec{x})^T]^T$
 $L''(\vec{x}, \vec{\lambda}) = [f''(\vec{x}) + \sum_{i=1}^m \lambda_i g''(\vec{x})_i, g'(\vec{x})^T]$
 • Lagr. mlt. množiny sestov. právě když $\nabla f(\vec{x}) \in G$ ($G = \text{span}\{g'(\vec{x}), \dots, g'(\vec{x})\}$)
 • podm. 2. řádu pro vztahy extrém: jako pro volné, ale def. $f''(\vec{x})$ vztahuje na $\text{null } g'(\vec{x})$

12. Lineární programování
 • $\min \{c^T x \mid x \in \mathbb{R}^n, Ax \geq b\}$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, $c \in \mathbb{R}^n$
 • $\min \{c^T x \mid x \in \mathbb{R}^n, Ax = b, x \geq 0\}$... rovnicový tvar
 $a^T x \geq b \Rightarrow a^T x - u = b, u \geq 0$
 $x \in \mathbb{R} \rightsquigarrow x = x^+ - x^-, x^+ \geq 0, x^- \geq 0$
 • p -normy $\|x\|_p = (|x_1|^p + \dots + |x_n|^p)^{1/p}$, $p \in [1, \infty]$
 $\|x\|_1 = |x_1| + \dots + |x_n|$... Manhattanova
 $\|x\|_\infty = \max\{|x_1|, \dots, |x_n|\}$... Čebyševova, max-norma
 $|x| = \max\{x, -x\}$

13. Konvexní množiny a mnohostěny
 • $X \subseteq \mathbb{R}^n$ je konvexní, pokud $\forall x, y \in X, \alpha \in [0, 1]: (1-\alpha)x + \alpha y \in X$
 • vztahy součel $\alpha_1 x_1 + \dots + \alpha_k x_k$ vektorů $x_1, \dots, x_k \in \mathbb{R}^n$ je
 lin. komb., jestliže $\alpha_1, \dots, \alpha_k \in \mathbb{R}$
 af. komb., jestliže $\alpha_1, \dots, \alpha_k \in \mathbb{R}, \alpha_1 + \dots + \alpha_k = 1$
 nerat. komb., jestliže $\alpha_1, \dots, \alpha_k \in \mathbb{R}, \alpha_1 + \dots + \alpha_k \neq 1$
 konv. komb., jestliže $\alpha_1, \dots, \alpha_k \in \mathbb{R}, \alpha_1 + \dots + \alpha_k = 1, \alpha_1, \dots, \alpha_k \geq 0$
 • konv. mnohostěn $X = \{\vec{x} \in \mathbb{R}^n \mid Ax \geq b\}$ (průnik konv. mnoh. rovnic)
 (uvnitř. poloprostor: $\{x \in \mathbb{R}^n \mid a^T x \geq b\}$)
 • bod $x \in X$ je extrémní bod mn. X , pokud
 $\forall x_1, x_2 \in X: x = \frac{1}{2}(x_1 + x_2) \Rightarrow x_1 = x_2$
 • pro konv. polyedr $X \neq \emptyset$: má alespoň 1 extr. bod \Leftrightarrow neobsahuje průměr

11. Lokální extrémy v rovině normostnosti (pohrácování)
 • podm. 2. řádu: $f: \mathbb{R}^n \rightarrow \mathbb{R}$ a $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ jsou 2krát dif. v $x \in \mathbb{R}^n$
 ex. λ tak, že $L'(x, \lambda) = 0 \wedge \begin{cases} L''(x, \lambda) \text{ poz. semidef. na } T \Leftrightarrow x \text{ lok. min.} \\ L''(x, \lambda) \text{ poz. def. na } T \Rightarrow x \text{ ostré lok. min.} \end{cases}$ var. $g(x) = 0$
 12. Lineární programování (pohrácování)
 • regrese polynomem nullého stupně $f(x, \theta) = \theta$: pro $\vec{g} = (g_1, \dots, g_m) \in \mathbb{R}^m$ hled. $\theta \in \mathbb{R}$
 $\min \|g - \theta \mathbf{1}\|_p = \min \|g_1 - \theta, \dots, g_m - \theta\|_p$
 $\rightarrow p = \infty$: $\min \max_{i=1, \dots, m} |g_i - \theta|$... řeš.: $\theta = \frac{1}{2}(\min_{i=1, \dots, m} g_i + \max_{i=1, \dots, m} g_i)$
 $\rightarrow p = 2$: $\min \sqrt{\sum_{i=1}^m (g_i - \theta)^2}$... řeš.: arit. průměr, tj. $\theta = \frac{1}{m} \sum_{i=1}^m g_i$
 $\rightarrow p = 1$: $\min \sum_{i=1}^m |g_i - \theta|$... řeš.: medián z čísel g_1, \dots, g_m
 • celočíselné lin. programování (ILP)
 $\min \{c^T x \mid x \in \{0, 1\}^n, Ax \geq b\} \rightsquigarrow \min \{c^T x \mid x \in [0, 1]^n, Ax \geq b\}$
 ILP s lineárními proměnnými LP relaxace úlohy
 $\min \{c^T x \mid x \in [0, 1]^n, Ax \geq b\} \leq \min \{c^T x \mid x \in \{0, 1\}^n, Ax \geq b\}$
 \rightarrow přizpůsobení problém: pro $c_{ij} \in \mathbb{R}, i, j \in \{1, 2, \dots, n\}$ hled. $\pi: \{1, \dots, n\} \rightarrow \{1, \dots, n\}$
 $\min \sum_{i=1}^n \sum_{j=1}^n c_{ij} x_{ij}$ kde platí:
 a. p. $\sum_{j=1}^n x_{ij} = 1 \quad i = 1, \dots, m$
 $\sum_{i=1}^m x_{ij} = 1 \quad j = 1, \dots, n$
 $x_{ij} \in \{0, 1\}$
 1) LP relaxace i pův. úloha mají stejnou opt. hodnotu
 2) mezi opt. řešeními LP relaxace ex. celočíselné
 \rightarrow nejm. vztahové pohyby: podm. $X \subseteq V$ vztahů tak, že každá hrana má alespoň 1 vztah (V.E) (chceme h a c se nejm. počtem vztahů) 1 vztah v X
 $\min \sum_{i \in V} x_i$
 a. p. $x_i + x_j \geq 1 \quad \{i, j\} \in E$
 $x_i \in \{0, 1\} \quad i \in V$
 • $x_i (i \in V)$ opt. řešení LP relaxace \rightsquigarrow
 $\bar{x}_i = \lfloor x_i + \frac{1}{2} \rfloor$ (je připuštěno pro nerelax. úlohu)
 • opt. hodnota \leq opt. hodnota pro nerelax. úlohu
 • platí $\bar{x} \leq 2x^*$ (pro nerelax. úlohu)

13. Konvexní množiny a mnohostěny (pohrácování)
 • bod x je extr. bod mnohostěnu \Leftrightarrow ex. $I \subseteq \{1, \dots, m\}$ tak, že $A_I x = b_I$ a A_I má LN sloupce
 • opěrná nadrovina konv. mn. $X \subseteq \mathbb{R}^n$ je $H = \{x \in \mathbb{R}^n \mid a^T x = b\}$ taková, že $X \cap H \neq \emptyset$
 a platí $a^T x \geq b$ pro vš. $x \in X$
 • $X \cap H$ je stěna mnohostěnu ($\dim = 0$: vrchol, $\dim = 1$: hrana, $\dim = \dim X - 1$: faceta)

15. Dualita v lineárním programování
 $\min c^T x$ $\max b^T y$ dualní
 $Ax \leq b$ $y \leq 0$
 $x \leq 0$ $A^T y \leq c$
 • slabá dualita: x ... přípust. prim. res., y ... příp. dualní res.
 $c^T x \geq b^T y$
 • komplementarita: $c^T x = b^T y$ iff:
 $\sum_{j \in I} \alpha_j x_j = b_i \vee y_i = 0 \quad \forall i \in I$
 $x_j = 0 \vee \sum_{i \in I} \alpha_j y_i = c_j \quad \forall j \in J$
 • silná dualita: 1) prim. úloha má opt. res. \Leftrightarrow dualní úloha má opt. res.
 2) prim. opt. res. x a dualní opt. res. $y \Rightarrow c^T x = b^T y$

prim./dual	má optimum	neomezená	nepřípustná
má optimum	✓	✗	✗
neomezená	✗	✗	✓
nepřípustná	✗	✓	✓

16. Konvexní funkce
 • $f: \mathbb{R}^n \rightarrow \mathbb{R}$ je konv. na konv. mn. $X \subseteq \mathbb{R}^n$, pokud pro vš. $x, y \in X, \alpha \in [0, 1]$:
 $f((1-\alpha)x + \alpha y) \leq (1-\alpha)f(x) + \alpha f(y)$
 • f je konv. $\Leftrightarrow -f$ je konk.
 • epigraf $\dots \{(\vec{x}, y) \in \mathbb{R}^{n+1} \mid f(\vec{x}) \leq y\}$
 • subkonkura vztahy $y \dots \{\vec{x} \in \mathbb{R}^n \mid f(\vec{x}) \leq y\}$
 • f je konv. \Leftrightarrow její epigraf je konv. mn.
 • každá subkonkura konv. fee je konv. mn.
 Všechny h. uvození konvexity: f konv., $x \in \mathbb{R}^n: f'(x) = 0 \Rightarrow x$ je glob. min. fee f
 1) konv. (lin./af.) = konv.
 2) konv. (konv.) = konv.
 3) $\sum \alpha_i g_i = \text{konv.}$, když $\alpha_i \geq 0$
 4) $\max g_i = \text{konv.}$
 5) $(\forall x, a \in \mathbb{R}^n: f(x) \geq f(a) + f'(a)(x-a)) \Leftrightarrow f$ konv. (pokud je f dif.)
 6) $(\forall x \in \mathbb{R}^n: f''(x) \text{ poz. semidef.}) \Leftrightarrow f$ konv. (pokud je f 2krát dif.)

17. Konvexní optimalizační úlohy
 • konv. úloha: min. konv. fee na konv. množině X
 \rightarrow ve standardním tvaru: $\min \{f(x) \mid x \in \mathbb{R}^n, g(x) \leq 0, h(x) = 0\}$
 \rightarrow každé lok. min. f na X je zároveň globální